

这份 `datapreprocess.py` 脚本的作用是**为地面探测站（DSN）调度系统生成模拟的高并发、多冲突基准数据集**。它通过数学分布随机生成了 40 台地面天线和 100 个航天器探测任务的复杂互斥关系。

以下是该数据集中所有参数及其业务含义的详细拆解：

一、 顶层任务参数 (Mission-level Parameters)

每个航天器任务（如 `JNO` 木星探测器或 `MIS-005` 随机任务）在 JSONL 文件中对应一行，包含以下全局属性：

参数名称	数据类型	业务含义与作用
<code>mission_id</code>	<code>String</code>	任务/航天器唯一标识符 。如经典任务模板中的 <code>"DAWN"</code> 、 <code>"JNO"</code> 或随机生成的 <code>"MIS-045"</code> 。
<code>total_requested_hr</code>	<code>Float</code>	总申请通信时长（小时） 。该航天器在这一周（168 小时）内，总共需要地面站提供多少小时的跟踪服务。这是计算最终 任务满意度 的分母。
<code>base_priority</code>	<code>Integer</code>	基础优先级（1-5） 。静态赋予该航天器的核心等级，数字越大越重要（1:常规模拟 $\rightarrow$ 5:不可重访的紧急飞掠）。它作为整个调度周期的“优先级底色”。
<code>priority_schedule</code>	<code>List[Dict]</code>	动态优先级时段表 。由于航天器在轨会遭遇突发事件（如飞掠或设备故障），其优先级会动态演变。该表将 168 小时切分成多段，详细定义了每个时间区间的实时优先级。
<code>activities</code>	<code>List[Dict]</code>	活动任务序列 。该航天器在这周内需要拆分执行的具体通信/探测事件列表。

`priority_schedule` 内嵌参数：

- `start_hr` / `end_hr`: 该优先级区间的开始与结束时间（单位：小时，范围 $0.0 \leq t \leq 168.0$ ）。
- `priority`: 该时段的实际优先级。脚本有 **30% 的概率**让某些时段的优先级在 `base_priority` 的基础上**提档 1~2 级**（最高封顶 5 级），以此模拟关键科学观测事件。

二、 活动参数 (Activity-level Parameters)

每个航天器任务旗下包含 $5 \sim 21$ 个不等的具体 `activities`（跟踪活动）。这些参数直接参与 MILP 模型中决策变量的物理约束控制：

参数名称	数据类型	业务含义与作用
<code>activity_id</code>	<code>String</code>	活动唯一标识符 。格式为 <code>"{mission_id}_ACT_{序号}"</code> ，是 MILP 模型中二进制决策变量 x_a 的变量名绑定源。
<code>d_min</code>	<code>Float</code>	单次通信最小持续时间（小时） 。允许调度器进行动态缩减的底线时间（通常为 2~4 小时）。

参数名称	数据类型	业务含义与作用
d_max	Float	单次通信最大（期望）持续时间（小时）。航天器本次科学下行最理想的连续跟踪时长（通常为 5~9 小时）。
setup_min	Integer	建链准备时间（分钟）。固定为 60 分钟。天线开机、转动指向航天器并进行射频对准所需的物理耗时。
teardown_min	Integer	关机拆除时间（分钟）。固定为 15 分钟。通信结束天线重置、日志归档所需的耗时。
can_split	Boolean	是否允许 XOR 拆分。脚本规定：如果期望最大时长 d_max $\geq$ 8.0 小时，则该任务允许被一拆为二。这为 MILP 算法提供了灵活变通的调度空间。
view_periods	List[Dict]	可选可见性窗口（几何视窗）。航天器由于轨道几何运动，在这周内可以被哪些地面天线在哪些时间段看到。

三、 视窗参数 (View Period Parameters)

view_periods 数组中包含了 ~ 4 个可选的天线窗口。这属于典型的“1对多”多备选空间：

- antenna: 指派的地面天线编号。扩充后的天线池包含 40 台天线（DSS-10 到 DSS-49），模拟分布在全球三大深空综合体的天线阵列。
- start_hr: 视窗开启时间（小时）。在一周 168 小时内随机均匀分布。
- end_hr: 视窗关闭时间（小时）。等于 start_hr 加上一个随机生成的几何可见时长（范围为 d_max 到 d_max + 6 小时），确保视窗长度大于活动最大需求，提供滑动排班余量。

四、 整体数据集的设计特征与隐性约束

这份数据并非盲目随机，其中隐藏了专门用来检验调度算法（Delta-MILP）健壮性的制造冲突机制：

1. 资源过载 (Over-subscription) :

低优先级任务（1级和2级）占比高达 45%，科学数据下行（3级）占 30%。大量低优先级任务在 168 小时内高频申请长达 5~9 小时的时段，使得整体需求远远超过 40 台天线总容量的 70% 阈值，从而暴露出巨大的时空碰撞冲突。

2. 刚性开销 (Overhead Block) :

每个活动不论大小，都要额外吞噬 60分钟(Setup) + 15分钟(Teardown) = 1.25小时 的不可视硬性天线时间。算法必须在消解冲突时合并或优化这些闲置开销。

3. 多约束交织:

同一个活动可能有 3 个可选视窗（分别对应 DSS-12、DSS-25、DSS-40），算法必须在多选的的同时，确保这个航天器（mission_id）不会在同一时刻被两台天线重复抓取（任务级互斥）。